Дообучение рекомендательной модели с RL на Yambda

Исследовательский проект по заданию T-Lab AI Research

1 Что я хотела проверить

Модель следующего трека учится продолжать историю пользователя. Но наиболее вероятное продолжение не обязательно лучшее по доле прослушивания или времени в сервисе. Я проверяю, можно ли изменить поведение GPT-2 с помощью RL и какую цену за это придётся заплатить в качестве рекомендаций.

Сначала обучается исходный рекомендатель, затем модель отклика — reward model (RM). Она оценивает историю и предложенный трек. После этого REINFORCE меняет вероятности рекомендаций в пользу действий с более высокой оценкой RM. **Прогноз награды повысить удалось, но убедительного улучшения релевантности я не получила.**

В проекте я опираюсь на две статьи. С GPTRec [1] связаны оптимизация свойств помимо точности, сравнение Top-5 с последовательной генерацией Next-5 и с reranking. Однако вместо PPO и обучения по спискам модели-учителя здесь используются REINFORCE и обученная RM. Со второй работой [2] связаны пятишаговый вариант и проверка влияния предполагаемых откликов на продолжение. В статье обучение идёт по записанным взаимодействиям с off-policy коррекцией; у меня действия генерирует текущая модель, а награды предсказывает RM. Это самостоятельный эксперимент, а не воспроизведение методов статей.

2 Данные и правила сравнения

Из Yambda-50M случайно выбраны 1 000 пользователей с не менее чем 20 событиями в обучающем периоде. Сохранены все их 5 477 104 события. Из-за ограничений вычислительных ресурсов каталог сокращён до 5 000 самых частых треков train, а обучение — до 100 000 примеров.

Данные разделены на train/validation/test в отношении 80/10/10 по времени, а не по числу строк. Каталог и статистики строятся только по train. Для каждого примера берутся последние 32 события строго раньше цели — реального следующего трека. События с временем цели в историю не попадают. Прошлые события с одинаковым временем упорядочены по ID: это техническое правило, их настоящий порядок неизвестен.

На тесте 4 927 целей, до пяти на пользователя. Сначала метрики усредняются внутри пользователя, затем между пользователями. Уже произошедшая тестовая история доступна, но веса моделей не обновляются. **Только 35,2% тестовых целей входят в каталог.** Остальные сохранены и считаются промахами, чтобы не завышать качество; отдельно в CSV показаны метрики на доступных целях.

3 Исходная модель и модель отклика

GPT-2 обучена с нуля на ID треков: два блока, скрытый размер 96, четыре головы внимания. Она предсказывает следующий трек по истории с помощью cross-entropy. Обучение: AdamW, learning rate 0.001, batch size 128, 12 эпох. Лучший checkpoint

выбран по validation NDCG@10; им оказалась последняя эпоха, на которой качество ещё росло. Знакомые треки разрешены, поскольку в музыке повторное прослушивание может быть уместным.

RM — небольшая нейросеть, которая получает представление истории из замороженной GPT-2, ID и длительность кандидата, а также сводки прошлого отклика пользователя. Она предсказывает долю прослушивания от 0 до 1. Значения выше 100% ограничены единицей; текущий отклик используется только как ответ при обучении. RM обучалась на тех же 100 000 примерах по MSE, checkpoint выбирался по validation RMSE.

Модель отклика	**MAE на test**	**RMSE на test**
Среднее прошлого отклика пользователя	0.29258	0.38040
Основная RM	0.29820	0.36370
RM с другим seed	0.30412	0.36533
RM без истории	0.40485	0.43024

На 1 735 тестовых взаимодействиях с треками из каталога основная RM лучше по RMSE, которая сильнее штрафует крупные ошибки. По средней абсолютной ошибке выигрывает среднее прошлого отклика. Вариант без истории, использующий только ID и длительность трека, заметно хуже. **Однозначного преимущества у RM нет**, поэтому дальше я проверяю не только её оценку, но и сами рекомендации. RM с другим seed использует те же данные и не является независимой проверкой пользовательской пользы.

4 Как устроено RL дообучение

Я использовала on-policy REINFORCE: действия выбираются из текущего распределения модели по всему каталогу. На одну историю генерируются четыре продолжения. Награда каждого сравнивается со средней наградой остальных трёх, чтобы уменьшить шум обучения. Дообучается копия GPT-2, а исходная модель и RM заморожены. KL-штраф удерживает распределение рекомендаций ближе к исходному; чем больше его вес β, тем сильнее ограничение.

Проверены шесть вариантов. Три повышают прогноз доли прослушивания при β = 0, 0.05 и 0.2. Вариант seconds умножает прогноз доли на длительность трека, ограниченную 95-м процентилем train, и делит на этот порог. Вариант repeat вычитает 0.2 за трек, уже присутствующий в контексте. Вариант ratio_h5_b005 оптимизирует среднюю награду пяти последовательных треков, учитывая влияние ранних действий на следующие шаги. У последних трёх вариантов β = 0.05.

Для каждого варианта использованы seeds 7, 17 и 27 — всего 18 запусков по 150 обновлений. Настройки RL: AdamW, learning rate 0.00003, 24 истории и четыре продолжения на историю.

Для сравнения добавлены продолженное next-item обучение на 150 обновлений и **reranking**: перестановка top-100 кандидатов по $\log \pi_0 + \alpha$ RM без изменения весов GPT-2. Проверены α = 1, 5 и 10. Одинаковое число обновлений не означает одинаковых вычислительных затрат.

На валидации выбран ratio_b0_s27: максимальная награда top-10 среди запусков с NDCG@10 не ниже 95% baseline. Этот порог — правило отбора, а не гарантия сохранения качества. После просмотра test настройки не менялись.

5 Что изменилось после RL

Все модели выдают top-10 из одного каталога. Recall@10 показывает попадание реального следующего трека, NDCG@10 учитывает его позицию. Прогноз RM — средняя оценка этих десяти треков по исходной истории пользователя.

Модель	Recall@10	NDCG@10	Прогноз RM
Popularity	0.01030	0.00487	0.69232
Исходная GPT-2	0.03045	0.01851	0.67939
Продолженное next-item обучение	0.03085	0.01845	0.67862
Reranking α = 5	0.03265	0.01891	0.68793
Reranking α = 10	0.03125	0.01858	0.69508
Выбранный RL ratio_b0_s27	0.03225	0.01856	0.68839

Награду повысить удалось, преимущество RL не установлено. Прогноз RM вырос с 0.67939 до 0.68839. NDCG немного вырос, но 95%-й интервал его изменения при bootstrap по пользователям [−0.000892; 0.001051] включает ноль. Поэтому этот прирост нельзя уверенно отличить от отсутствия эффекта. Reranking дал сопоставимые результаты: при α = 5 — самые высокие значения точности в таблице, при α = 10 — наибольший прогноз RM. Даже Popularity получает высокую награду при низкой точности: одной оценки RM недостаточно.

Изменилось и содержание выдачи. Средняя длительность треков снизилась со 192.3 до 187.0 секунды. При оптимизации секунд вариант с seed 7, наоборот, выбирает треки длительностью 197.6 секунды. Это согласуется с предположением, что награда за долю прослушивания поощряет короткие треки, хотя влияние длительности не отделено от других свойств объектов.

Покрытие каталога сократилось с 80.3% до 76.9%, а доля показов десяти самых часто рекомендуемых треков выросла с 7.0% до 8.7%. Выдача стала более концентрированной, но одинаковых списков для всех не получилось. При росте β средняя награда по seeds снижается: 0.6883 → 0.6861 → 0.6827. Штраф за знакомые треки помог слабо: их доля при seed 7 составила 0.1095 против 0.1103 у baseline.

6 Что происходит за пять шагов

На одинаковых 512 тестовых контекстах сравниваются **Top-5** — пять лучших разных треков за один проход — и **Next-5**, где каждый выбранный трек добавляется в историю перед следующим выбором. Вариант unique запрещает повторы внутри списка. NDCG@5 оценивает попадание одного реального следующего трека; повторное попадание не даёт дополнительных баллов. Прогноз RM для сравнения рассчитан по исходной истории. Эти результаты нельзя напрямую сопоставлять с NDCG@10 на всём тесте.

Модель и способ выдачи	NDCG@5	Прогноз RM	Доля дублей
Baseline Top-5	0.02426	0.68672	0
Baseline Next-5	0.02378	0.68816	0.7256
Выбранный RL Top-5	0.02122	0.69501	0
Выбранный RL Next-5	0.01358	0.69895	0.7369

Выбранный RL Next-5 unique	0.01576	0.69330	0
Пятишаговый RL Next-5 при seed 7	0.01605	0.69672	0.7330

Главная проблема — повторы. У выбранного RL остаётся в среднем 1.32 уникального трека из пяти. Повторы есть и у baseline, поэтому объяснять их только влиянием RL нельзя. Запрет дублей повышает NDCG, но не возвращает качество Top-5. Пятишаговое обучение в показанном запуске тоже не решило проблему.

Отдельно я проверила влияние предполагаемого отклика. При генерации трек считается принятым, а вместо неизвестной доли прослушивания в историю подставляется прогноз RM. У выбранного RL на пятом шаге один и тот же кандидат получает в среднем 0.7360 при обновлении треков и откликов, 0.7080 при обновлении только треков и 0.7028 по исходной истории. **Часть роста оценки возникает потому, что RM получает на вход собственные прогнозы.** Это не доказывает, что пользователю понравится продолжение.

7 Что бы я делала дальше

Награду можно дополнить продолжением сессии или возвращением пользователя через сутки либо неделю. Для таких меток нужно определить границы сессии и полностью наблюдать будущий период: если данные заканчиваются через час, отсутствие возвращения за неделю ещё неизвестно. Всё окно обучающей метки должно оставаться внутри train.

Офлайн можно проверить, предсказывает ли RM историческое возвращение и сохраняется ли качество в следующем периоде. Но связь трека с возвращением ещё не доказывает причину: влияние новой политики нужно проверять онлайн. Отдельная модель возвращения здесь не обучалась — это возможное продолжение исследования.

8 Выводы

Модель научилась получать более высокую оценку RM, но пока нет оснований считать, что рекомендации стали полезнее пользователю. Выдача стала менее разнообразной, треки — короче, а последовательная генерация сохранила частые повторы. Простой reranking оказался конкурентоспособным без RL-дообучения.

Выводы ограничены небольшим каталогом и выборкой. Исходная GPT-2 обучена с одним seed, а RM видела только наблюдавшиеся взаимодействия. Следующим шагом я бы расширила каталог, повторила обучение baseline с несколькими seeds и проверила RM на рекомендациях, отличающихся от исторических. Для нескольких шагов нужно учитывать пропуски треков и завершение сессии. Новые варианты следует оценивать на ещё не использованном временном периоде.

Источники

[1] Aligning GPTRec with Beyond-Accuracy Goals with Reinforcement Learning.
https://arxiv.org/abs/2403.04875

[2] Session-Level Optimization for Large-Scale Retrieval using REINFORCE with Multi-Step Off-Policy Correction.
https://arxiv.org/abs/2607.02818